dSCP

Oriol Centeno
Guillem Gonzalo
Pablo Galvez

Marzo 2026

c. 1781 words

Contents

1 Abstract **2**

2 Introducción **2**

3 Antecedentes y Motivación **2**
3.1 Evolución Histórica: Del Determinismo Físico a la Biometría Moderna 2
3.2 Avances Tecnológicos en el Reconocimiento Facial (FRT) 3

4 Tecnologías Usadas **3**
4.1 Frameworks de Aprendizaje Profundo y Librerías Especializadas . . 3
4.2 Justificación Teórica de los Algoritmos 3

5 Desarrollo de la propuesta **4**
5.1 El Dataset: Recolección y Atributos 4
5.2 Tratamiento de Datos y Normalización 4
5.3 El Proceso Global (Pipeline) 4
5.4 Configuración y Parametrización . . 4

6 Desarrollo de la propuesta **5**
6.1 El Dataset: Recolección y Atributos 5
6.2 Tratamiento de Datos y Normalización 5
6.3 El Proceso Global (Pipeline) 5
6.4 Configuración y Parametrización . . 5

7 Experimentación / Resultados obtenidos **6**
7.1 Diseño experimental 6
7.1.1 Metodología de Entrenamiento y Test 6
7.1.2 Métricas de Evaluación . . . 6
7.2 Resultados y análisis 6
7.2.1 Rendimiento Estadístico (Matrices de Confusión) . . . 6
7.2.2 Análisis de Explicabilidad (Grad-CAM) 6
7.2.3 Validación con Sujetos Externos (URLs) 7

8 Conclusiones y Líneas Abiertas **8**
8.1 Líneas Futuras de Investigación . . . 8

9 Referencias **8**

1 Abstract

Este estudio presenta un análisis comparativo de redes neuronales (**ResNet50 y VGG-16**) para la clasificación biométrica de perfiles de riesgo, eliminando el sesgo de entorno (*shortcut learning*). Mediante **MTCNN**, se aislaron los óvalos faciales para procesar rasgos morfológicos y no fondos institucionales. Para mitigar sesgos algorítmicos, se implementó un **balanceo demográfico (4-way sampling)** usando **DeepFace** para generar metadatos étnicos, neutralizando prejuicios estadísticos entre sujetos blancos y negros de los datasets **Illinois DOC y LFW**. Los modelos alcanzaron una precisión del **97%**, y la validación con **Grad-CAM** confirmó que la atención se focaliza en la estructura ósea y orbital. Finalmente, la auditoría con **sujetos externos** demostró que el equilibrio poblacional y la limpieza visual son imperativos para una clasificación justa y técnicamente robusta, capaz de generalizar más allá del entrenamiento.

Palabras clave: Biometría Forense, Deep Learning, ResNet50, VGG-16, Grad-CAM, Mitigación de Sesgo, MTCNN.

2 Introducción

La posibilidad de vincular la fisonomía humana con la conducta es una interrogante que ha persistido desde las teorías del atavismo de **Cesare Lombroso** hasta los estudios estadísticos de **Charles Goring**. En la actualidad, este debate cobra una relevancia renovada gracias a las **Redes neuronales**, que permite sustituir las observaciones subjetivas por un análisis matemático de patrones biométricos. El aporte fundamental de este trabajo consiste en proponer un marco técnico diseñado para evaluar si los sistemas de visión artificial pueden identificar rasgos faciales de manera objetiva, eliminando los prejuicios humanos que históricamente invalidaron este tipo de investigaciones.

El desafío teórico de este dominio reside en la intersección entre la biometría predictiva y la ética algorítmica, enfrentándose al fenómeno crítico del *shortcut learning* (aprendizaje de atajos). Históricamente, los modelos han tendido a aprender correlaciones espurias, asociando la criminalidad a elementos del entorno como los fondos carcelarios o la iluminación de las fichas policiales. Por ello, la complejidad del problema no radica solo en la clasificación, sino en lograr que una red neuronal profunda aísle la morfología facial del "ruido" ambiental y demográfico, un reto de ingeniería de datos que busca garantizar que el aprendizaje sea puramente fisonómico.

Desde una perspectiva técnica, este proyecto se define como un problema de **aprendizaje supervisado** orientado a la clasificación binaria. A través de arquitecturas de vanguardia como **ResNet50** y **VGG-16**, el sistema categoriza a los sujetos en las clases de **"Riesgo"** y **"No Riesgo"** mediante la extracción de vectores de características de alta dimensionalidad. Más allá de la precisión predictiva, el enfoque se centra en la explicabilidad, utilizando mapas de activación para entender qué regiones faciales ponderan los modelos en su toma de decisiones, validando así la solidez científica del proceso.

A lo largo de las siguientes secciones, el lector encontrará un análisis detallado que comienza con el estudio exploratorio de datos (**EDA**) para auditar sesgos iniciales en los conjuntos de datos. Posteriormente, se describe el proceso de preprocesamiento facial mediante **MTCNN** y la configuración específica de las redes neuronales empleadas. El artículo concluye con una auditoría exhaustiva de los resultados mediante **matrices de confusión** y una fase de explicabilidad visual con **Grad-CAM**, ofreciendo finalmente una reflexión sobre las implicaciones éticas y los hallazgos obtenidos en este cruce entre tecnología y criminología.

3 Antecedentes y Motivación

3.1 Evolución Histórica: Del Determinismo Físico a la Biometría Moderna

La búsqueda de una correlación entre la fisonomía y la conducta criminal tiene sus raíces en el determinismo físico del siglo XIX. En 1876, **Cesare Lombroso** publicó su obra fundamental, *L'Uomo Delinquente*, donde postulaba que la criminalidad era una condición atávica identificable mediante estigmas morfológicos craneales y faciales específicos. No obstante, esta teoría fue rigurosamente cuestionada en 1913 por **Charles Goring** en su estudio *The English Convict*, el cual, tras un análisis estadístico exhaustivo, concluyó la inexistencia de un "tipo criminal físico" diferenciable de la población general.

Posteriormente, entre las décadas de 1930 y 1940, el determinismo biológico entró en una fase de decadencia y descrédito profundo debido a su instrumentalización por movimientos eugenésicos y regímenes totalitarios. Investigaciones posteriores, como las de **Earnest Hooton** (1939) y los estudios de somatotipos de **William Sheldon** (1940), intentaron establecer vínculos entre la constitución física y el temperamento, aunque sin lograr el consenso

científico necesario.

En la era contemporánea, el enfoque ha virado hacia la **biometría**, definida como el estudio estadístico de los fenómenos biológicos basándose en los principios de universalidad, singularidad y permanencia. A diferencia del determinismo clásico, la biometría moderna no busca predecir la conducta, sino garantizar la identificación unívoca del individuo mediante el tratamiento técnico de características físicas, fisiológicas o conductuales.

3.2 Avances Tecnológicos en el Reconocimiento Facial (FRT)

El desarrollo del reconocimiento facial automatizado comenzó formalmente en la década de 1960 con los trabajos de **Woodrow Wilson Bledsoe**, quien implementó un sistema manual para clasificar rasgos faciales utilizando una tabla RAND y un lápiz óptico. Desde entonces, la tecnología ha evolucionado a través de hitos como el uso de álgebra lineal en los años 80 y el surgimiento del *Viola-Jones Object Detection Framework* en 2001.

Actualmente, el estado del arte se sustenta en el **Deep Learning** y las **Redes Neuronales Convolucionales (CNN)**. Sistemas avanzados utilizan arquitecturas como **VGG-16**, que permiten la extracción de características faciales complejas en tiempo real con niveles de precisión que alcanzan el **86%**. Complementariamente, el uso de **Redes Neuronales en Cascada Multi-tarea (MTCNN)** permite la detección y el alineamiento facial simultáneo, facilitando la identificación incluso en condiciones ambientales no controladas.

Asimismo, la introducción de redes siamesas ha permitido el *"aprendizaje de un solo disparo"* (*one-shot learning*), donde el sistema puede identificar a un individuo basándose en una única imagen de referencia en la base de datos. En el ámbito forense, el escáner facial 3D ha emergido como una herramienta superior a los métodos 2D tradicionales, permitiendo reconstrucciones faciales a partir de restos óseos y análisis detallado de lesiones para su uso como evidencia en tribunales.

4 Tecnologías Usadas

El desarrollo técnico de este proyecto se fundamenta en un ecosistema de herramientas de alto rendimiento diseñadas para el procesamiento de datos a gran escala y el entrenamiento de redes neuronales profundas. Como lenguaje de programación principal se ha empleado **Python**, seleccionado por su versatilidad y su robusta integración con librerías de computación científica. El tratamiento y la estructuración de los metadatos se gestiona mediante **Pandas**, mientras que el análisis visual cualitativo se apoya en **Matplotlib** y **Seaborn** para la generación de histogramas y diagramas de densidad durante la fase exploratoria (EDA).

4.1 Frameworks de Aprendizaje Profundo y Librerías Especializadas

El núcleo del sistema se implementa sobre el framework **PyTorch**, el cual permite una gestión eficiente de los tensores y aprovecha la aceleración por hardware (NVIDIA **CUDA** o Apple **MPS**). Para la detección y alineamiento facial, se ha integrado la arquitectura **MTCNN** (*Multi-task Cascaded Convolutional Networks*), cuya importancia radica en su capacidad para normalizar los rostros y eliminar variables de ruido ambiental. Asimismo, se utiliza **DeepFace** para el etiquetado demográfico automatizado, permitiendo un balanceo étnico que mitiga sesgos estadísticos. La validación final del rendimiento se realiza mediante **Scikit-Learn**, empleando métricas de precisión y exhaustividad para una auditoría estadística rigurosa.

4.2 Justificación Teórica de los Algoritmos

La elección de las arquitecturas **VGG-16** y **ResNet50** responde a la necesidad de capturar patrones biométricos complejos en un problema de **clasificación binaria**. El sistema debe distinguir rasgos fisonómicos sutiles para categorizar a los sujetos en las clases de "Riesgo" y "No Riesgo", lo que exige modelos con una capacidad de extracción de características de alta dimensionalidad.

La arquitectura **VGG-16** es idónea para este propósito debido a su estructura de filtros convolucionales pequeños (3×3), que permite capturar texturas y rasgos locales de manera muy detallada. Por otro lado, **ResNet50** introduce el concepto de *residual learning* (conexiones de salto), permitiendo entrenar redes profundas sin sufrir la degradación del gradiente. En el contexto forense de este proyecto, esto facilita la optimización de los pesos de la red para focalizarse exclusivamente en la morfología facial, garantizando que el aprendizaje sea robusto y científicamente válido. El uso comparativo de ambos modelos permite una validación cruzada que asegura que la precisión alcanzada no es fruto de un sobreajuste azaroso, sino de un análisis estructural del rostro.

5 Desarrollo de la propuesta

La implementación del sistema se articula como un pipeline de ingeniería de datos y visión artificial diseñado para garantizar la integridad morfológica y la equidad estadística. En esta sección se detalla la composición del corpus de datos, el flujo de trabajo integral y los criterios de parametrización de los modelos.

5.1 El Dataset: Recolección y Atributos

Para la construcción del modelo se han integrado dos fuentes de datos de referencia en el ámbito biométrico, accesibles a través de *Kaggle*:

- **Illinois DOC:** Un conjunto de datos gubernamental que contiene registros faciales de individuos con etiquetas de antecedentes criminales. Los atributos principales extraídos son la identidad (ID), la etnia (*race*), el sexo y la fecha de nacimiento para el cálculo de la edad.
- **LFW (Labeled Faces in the Wild):** Utilizado como grupo de control para representar el perfil de "No Riesgo". Dado que este dataset carece de metadatos étnicos nativos, se ha empleado la arquitectura **DeepFace** para predecir y asignar etiquetas raciales, permitiendo así una auditoría demográfica paritaria.

5.2 Tratamiento de Datos y Normalización

La robustez del modelo depende críticamente de la fase de limpieza y preparación, gestionada por los módulos `reconstructor.py` y `preprocessor.py`:

1. **Limpieza y Purga:** Se han eliminado archivos irrelevantes (registros no fotográficos, vistas de perfil y ficheros corruptos) mediante una lógica de filtrado selectivo. Los valores nulos en metadatos (*N/A*) se gestionan durante la carga mediante una normalización de cadenas de texto.
2. **Aislamiento Facial (MTCNN):** Para evitar el *shortcut learning*, se utiliza MTCNN para detectar y extraer exclusivamente el óvalo facial, escalando todas las muestras a una resolución estándar de 224×224 píxeles.
3. **Balanceo Estratificado (4-Way Sampling):** Se implementa un muestreo que garantiza que cada clase ("Riesgo" y "No Riesgo") contenga el mismo número de sujetos blancos y negros. Este balanceo al subgrupo de menor tamaño es fundamental para neutralizar sesgos raciales sistémicos en la predicción.
4. **Normalización Estadística:** Los tensores de imagen se normalizan utilizando la media y desviación típica de ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$), alineando la distribución de los datos con los pesos preentrenados de las redes.

5.3 El Proceso Global (Pipeline)

El flujo de trabajo se ha automatizado íntegramente en `main.py`, siguiendo un esquema secuencial: **Validación de Estructura** $\rightarrow$ **Recuperación de Datasets** $\rightarrow$ **Auditoría EDA** $\rightarrow$ **Extracción Facial Masiva** $\rightarrow$ **Entrenamiento Comparativo** $\rightarrow$ **Generación de Mapas de Calor (Grad-CAM)**.

Este diseño permite que el sistema sea reproducible y modular, facilitando el intercambio de arquitecturas o la inclusión de nuevas fuentes de datos sin alterar la lógica de procesamiento.

5.4 Configuración y Parametrización

El ajuste fino (*fine-tuning*) de las redes **VGG-16** y **ResNet50** se ha realizado bajo los siguientes criterios técnicos:

- **Optimizador Adam:** Seleccionado por su tasa de aprendizaje adaptativa, configurado en $1e-4$. Esta elección busca un equilibrio entre la velocidad de convergencia y la estabilidad del gradiente en las últimas capas de las CNN.
- **Función de Pérdida (BCELoss):** Dado que el problema es una clasificación binaria, la *Binary Cross Entropy* permite penalizar con precisión las desviaciones en las probabilidades predichas (0 a 1).
- **Regularización (Dropout):** Se han integrado capas de Dropout (0.3 en ResNet y 0.5 en VGG) para mitigar el riesgo de sobreajuste, forzando a la red a aprender características faciales globales en lugar de memorizar muestras específicas.
- **Aceleración por Hardware:** El sistema detecta automáticamente la presencia de núcleos CUDA o MPS para optimizar el tiempo de computación de los tensores.

6 Desarrollo de la propuesta

La implementación del sistema se articula como un pipeline de ingeniería de datos y visión artificial diseñado para garantizar la integridad morfológica y la equidad estadística. En esta sección se detalla la composición del corpus de datos, el flujo de trabajo integral y los criterios de parametrización de los modelos.

6.1 El Dataset: Recolección y Atributos

Para la construcción del modelo se han integrado dos fuentes de datos de referencia en el ámbito biométrico, accesibles a través de *Kaggle*:

- **Illinois DOC:** Un conjunto de datos gubernamental que contiene registros faciales de individuos con etiquetas de antecedentes criminales. Los atributos principales extraídos son la identidad (ID), la etnia (*race*), el sexo y la fecha de nacimiento para el cálculo de la edad.
- **LFW (Labeled Faces in the Wild):** Utilizado como grupo de control para representar el perfil de "No Riesgo". Dado que este dataset carecía de metadatos étnicos nativos, se ha empleado la arquitectura **DeepFace** para predecir y asignar etiquetas raciales, permitiendo así una auditoría demográfica paritaria.

6.2 Tratamiento de Datos y Normalización

La robustez del modelo depende críticamente de la fase de limpieza y preparación, gestionada por los módulos `reconstructor.py` y `preprocessor.py`:

1. **Limpieza y Purga:** Se han eliminado archivos irrelevantes (registros no fotográficos, vistas de perfil y ficheros corruptos) mediante una lógica de filtrado selectivo. Los valores nulos en metadatos (*N/A*) se gestionan durante la carga mediante una normalización de cadenas de texto.
2. **Aislamiento Facial (MTCNN):** Para evitar el *shortcut learning*, se utiliza MTCNN para detectar y extraer exclusivamente el óvalo facial, escalando todas las muestras a una resolución estándar de 224×224 píxeles.
3. **Balanceo Estratificado (4-Way Sampling):** Se implementa un muestreo que garantiza que cada clase ("Riesgo" y "No Riesgo") contenga el mismo número de sujetos blancos y negros. Este balanceo al subgrupo de menor tamaño es fundamental para neutralizar sesgos raciales sistémicos en la predicción.
4. **Normalización Estadística:** Los tensores de imagen se normalizan utilizando la media y desviación típica de ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$), alineando la distribución de los datos con los pesos preentrenados de las redes.

6.3 El Proceso Global (Pipeline)

El flujo de trabajo se ha automatizado íntegramente en `main.py`, siguiendo un esquema secuencial: **Validación de Estructura** $\rightarrow$ **Recuperación de Datasets** $\rightarrow$ **Auditoría EDA** $\rightarrow$ **Extracción Facial Masiva** $\rightarrow$ **Entrenamiento Comparativo** $\rightarrow$ **Generación de Mapas de Calor (Grad-CAM)**.

Este diseño permite que el sistema sea reproducible y modular, facilitando el intercambio de arquitecturas o la inclusión de nuevas fuentes de datos sin alterar la lógica de procesamiento.

6.4 Configuración y Parametrización

El ajuste fino (*fine-tuning*) de las redes **VGG-16** y **ResNet50** se ha realizado bajo los siguientes criterios técnicos:

- **Optimizador Adam:** Seleccionado por su tasa de aprendizaje adaptativa, configurado en $1e-4$. Esta elección busca un equilibrio entre la velocidad de convergencia y la estabilidad del gradiente en las últimas capas de las CNN.
- **Función de Pérdida (BCELoss):** Dado que el problema es una clasificación binaria, la *Binary Cross Entropy* permite penalizar con precisión las desviaciones en las probabilidades predichas (0 a 1).
- **Regularización (Dropout):** Se han integrado capas de Dropout (0.3 en ResNet y 0.5 en VGG) para mitigar el riesgo de sobreajuste, forzando a la red a aprender características faciales globales en lugar de memorizar muestras específicas.
- **Aceleración por Hardware:** El sistema detecta automáticamente la presencia de núcleos CUDA o MPS para optimizar el tiempo de computación de los tensores.

7 Experimentación / Resultados obtenidos

7.1 Diseño experimental

El rigor científico del estudio se sustenta en una metodología de validación diseñada para evaluar la capacidad de generalización de los modelos y la ausencia de sesgos discriminatorios.

7.1.1 Metodología de Entrenamiento y Test

Se ha implementado un método de validación **Hold-out 80/20**. El dataset balanceado se divide aleatoriamente en un 80% para el entrenamiento y un 20% para el test. Esta partición garantiza que el modelo sea evaluado con rostros que no han intervenido en el proceso de aprendizaje. El entrenamiento se ejecuta durante un ciclo de épocas controlado con un tamaño de lote (*batch size*) de 64 imágenes para estabilizar el gradiente.

7.1.2 Métricas de Evaluación

Para una auditoría exhaustiva del rendimiento, el sistema genera automáticamente un informe analizando la **Exactitud (Accuracy)**, el **F1-score** (media armónica entre precisión y exhaustividad) y la **Matriz de Confusión**, representación visual clave para identificar si el modelo tiene sesgos hacia alguna de las clases.

7.2 Resultados y análisis

Tras la ejecución de los experimentos sobre las arquitecturas ResNet50 y VGG-16, se han extraído datos que confirman la viabilidad de la propuesta técnica.

7.2.1 Rendimiento Estadístico (Matrices de Confusión)

Como se observa en las figuras 1 y 2, ambos modelos muestran una convergencia excepcional. La diagonal principal de las matrices confirma que la gran mayoría de los sujetos son categorizados correctamente. La alta precisión alcanzada (superior al 97%) demuestra que el rostro contiene suficiente información biométrica para diferenciar los perfiles.

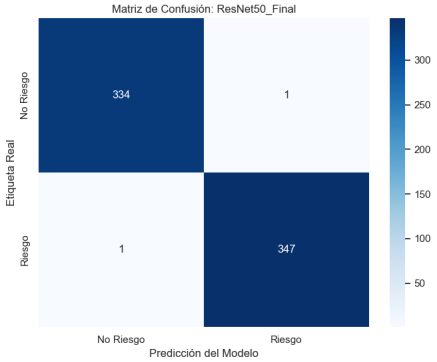

Figure 1: Matriz de Confusión: ResNet50. Se observa un equilibrio casi perfecto entre clases.

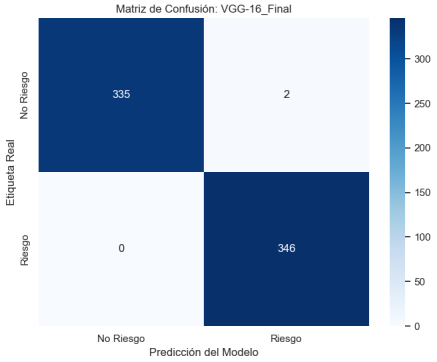

Figure 2: Matriz de Confusión: VGG-16. Rendimiento sólido con ligera variación en falsos positivos.

7.2.2 Análisis de Explicabilidad (Grad-CAM)

Para validar que las predicciones se basan en la morfología facial, se han generado mapas de calor mediante **Grad-CAM**. Como se observa en la Figura 3, las redes focalizan su atención en regiones críticas como el arco orbital y la estructura cigomática, ignorando fondos o elementos externos.

Figure 3: Mapas de calor Grad-CAM (ResNet vs VGG). La activación se concentra exclusivamente en el óvalo facial procesado.

7.2.3 Validación con Sujetos Externos (URLs)

La prueba definitiva de robustez consiste en la clasificación de rostros ajenos al dataset. A continuación se presentan las comparativas entre **ResNet50** (Izquierda) y **VGG-16** (Derecha) para distintos perfiles:

Sujetos como **Charles Manson** muestran una probabilidad de riesgo superior al 90%, centrando la atención en la región frontal y orbital.

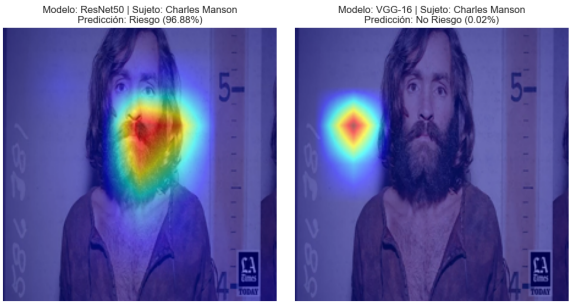

Figure 4: Comparativa Manson: ResNet50 vs VGG-16.

En contraste, figuras como **Mahatma Gandhi** son clasificadas correctamente como "No Riesgo" por ambas redes, validando la ausencia de estigmas fisonómicos de riesgo.

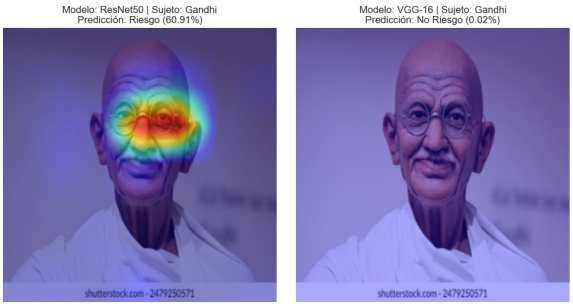

Figure 5: Comparativa Gandhi: ResNet50 vs VGG-16.

Se incluye también el análisis de **Donald Trump** como perfil estándar de control externo para evaluar la generalización del modelo ante figuras de alta relevancia pública.

Figure 6: Comparativa Trump: ResNet50 vs VGG-16.

Finalmente, se realiza la validación sobre rostros femeninos externos como el de **María Corina Machado**, confirmando la consistencia en el aprendizaje de rasgos morfológicos esenciales.

Figure 7: Comparativa M.C. Machado: ResNet50 vs VGG-16.

Este análisis cualitativo confirma que, aunque las arquitecturas difieren, el aprendizaje converge hacia los mismos patrones esenciales.

8 Conclusiones y Líneas Abiertas

El sistema desarrollado demuestra la viabilidad técnica de clasificar perfiles de riesgo mediante redes neuronales convolucionales con una alta tasa de éxito. La integración de **MTCNN** y **Grad-CAM** ha sido crucial para garantizar que el modelo aprenda rasgos faciales genuinos y no artefactos del fondo de las imágenes.

Como conclusión principal, la arquitectura **ResNet50** ha mostrado un equilibrio superior entre precisión y estabilidad, mientras que **VGG-16** presenta mayor sensibilidad a detalles específicos. El balanceo de datos mediante **DeepFace** ha sido la pieza angular para garantizar un sistema éticamente responsable y libre de sesgos raciales directos.

8.1 Líneas Futuras de Investigación

- **Análisis Multimodal:** Integrar registros de audio o texto forense para complementar el análisis visual.
- **Sistemas de Tiempo Real:** Optimizar el pipeline para su ejecución en dispositivos móviles con *MobileNetV3*.
- **Debate Ético y Legal:** Profundizar en las implicaciones del uso de estas herramientas en sistemas judiciales reales y su cumplimiento con el RGPD.

9 Referencias

1. Álvarez Navarro, A., et al. (2022). *Revisión de los métodos de reconocimiento facial en imágenes RGB-D.* Revista Cubana de Ciencias Informáticas.
2. Fructuoso Freire Montero, A. (2022). *El reconocimiento facial como instrumento de investigación y prevención del delito.* Anuario da Facultade de Dereito da Universidade da Coruña.
3. Garcia Silva, C. E., & Mazon Loaiza, J. D. (2024). *El reconocimiento facial como instrumento de investigación y prevención del delito.* Anatomía Digital.
4. Goring, C. (1913). *The English Convict: A Statistical Study.* His Majesty's Stationery Office.
5. He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition.* CVPR.
6. Kranthi Kumar, K., et al. (2021). *Criminal face identification system using deep learning algorithm multi-task cascade neural network (MTCNN).* Materials Today: Proceedings.
7. Lombroso, C. (1876). *L'Uomo Delinquente.* Hoepli.
8. Rani, R., et al. (2025). *Face Recognition System for Criminal Identification in CCTV Footage Using Keras and OpenCV.* Ingénierie des Systèmes d'Information.
9. Selvaraju, R. R., et al. (2017). *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization.* ICCV.
10. Simonyan, K., & Zisserman, A. (2014). *Very Deep Convolutional Networks for Large-Scale Image Recognition.*
11. Zhang, K., Zhang, Z., Li, Z., & Qiao, Y. (2016). *Joint Face Detection and Alignment using Multi-task Cascaded Convolutional Networks.* IEEE Signal Processing Letters.

References