dSCP

Oriol Centeno
Guillem Gonzalo
Pablo Galvez

Marzo 2026

c. 1781 words

Contents

1 Abstract **2**

2 Introducción **2**

3 Antecedentes y Motivación **2**
3.1 Evolución Histórica: Del Determinismo Físico a la Biometría Moderna 2
3.2 Avances Tecnológicos en el Reconocimiento Facial (FRT) 3

4 Tecnologías Usadas **3**
4.1 Frameworks de Aprendizaje Profundo y Librerías Especializadas . . 3
4.2 Justificación Teórica de los Algoritmos 3

5 Desarrollo de la propuesta **4**
5.1 El Dataset: Recolección y Atributos 4
5.2 Tratamiento de Datos y Normalización 4
5.3 El Proceso Global (Pipeline) 4
5.4 Configuración y Parametrización . . 4

6 Desarrollo de la propuesta **5**
6.1 El Dataset: Recolección y Atributos 5
6.2 Tratamiento de Datos y Normalización 5
6.3 El Proceso Global (Pipeline) 5
6.4 Configuración y Parametrización . . 5

7 Experimentación / Resultados obtenidos **6**
7.1 Diseño experimental 6
7.1.1 Metodología de Entrenamiento y Test 6
7.1.2 Métricas de Evaluación . . . 6
7.2 Resultados y análisis 6
7.2.1 Rendimiento Estadístico (Matrices de Confusión) . . . 6
7.2.2 Análisis de Explicabilidad (Grad-CAM) 6
7.2.3 Validación con Sujetos Externos (URLs) 7

8 Discusión abierta **9**

9 Conclusiones y Líneas Abiertas **10**
9.1 Líneas Futuras de Investigación . . . 10

1 Abstract

Este estudio presenta un análisis comparativo de redes neuronales (**ResNet50 y VGG-16**) para la clasificación biométrica de perfiles de riesgo, eliminando el sesgo de entorno (*shortcut learning*). Mediante **MTCNN**, se aislaron los óvalos faciales para procesar rasgos morfológicos y no fondos institucionales. Para mitigar sesgos algorítmicos, se implementó un **balanceo demográfico (4-way sampling)** usando **DeepFace** para generar metadatos étnicos, neutralizando prejuicios estadísticos entre sujetos blancos y negros de los datasets **Illinois DOC y LFW**. Los modelos alcanzaron una precisión del **97%**, y la validación con **Grad-CAM** confirmó que la atención se focaliza en la estructura ósea y orbital. Finalmente, la auditoría con **sujetos externos** demostró que el equilibrio poblacional y la limpieza visual son imperativos para una clasificación justa y técnicamente robusta, capaz de generalizar más allá del entrenamiento.

Palabras clave: Biometría Forense, Deep Learning, ResNet50, VGG-16, Grad-CAM, Mitigación de Sesgo, MTCNN.

2 Introducción

La posibilidad de vincular la fisonomía humana con la conducta es una interrogante que ha persistido desde las teorías del atavismo de **Cesare Lombroso** hasta los estudios estadísticos de **Charles Goring**. En la actualidad, este debate cobra una relevancia renovada gracias a las **Redes neuronales**, que permite sustituir las observaciones subjetivas por un análisis matemático de patrones biométricos. El aporte fundamental de este trabajo consiste en proponer un marco técnico diseñado para evaluar si los sistemas de visión artificial pueden identificar rasgos faciales de manera objetiva, eliminando los prejuicios humanos que históricamente invalidaron este tipo de investigaciones.

El desafío teórico de este dominio reside en la intersección entre la biometría predictiva y la ética algorítmica, enfrentándose al fenómeno crítico del *shortcut learning* (aprendizaje de atajos). Históricamente, los modelos han tendido a aprender correlaciones espurias, asociando la criminalidad a elementos del entorno como los fondos carcelarios o la iluminación de las fichas policiales. Por ello, la complejidad del problema no radica solo en la clasificación, sino en lograr que una red neuronal profunda aísle la morfología facial del "ruido" ambiental y demográfico, un reto de ingeniería de datos que busca garantizar que el aprendizaje sea puramente fisonómico.

Desde una perspectiva técnica, este proyecto se define como un problema de **aprendizaje supervisado** orientado a la clasificación binaria. A través de arquitecturas de vanguardia como **ResNet50** y **VGG-16**, el sistema categoriza a los sujetos en las clases de **"Riesgo"** y **"No Riesgo"** mediante la extracción de vectores de características de alta dimensionalidad. Más allá de la precisión predictiva, el enfoque se centra en la explicabilidad, utilizando mapas de activación para entender qué regiones faciales ponderan los modelos en su toma de decisiones, validando así la solidez científica del proceso.

A lo largo de las siguientes secciones, el lector encontrará un análisis detallado que comienza con el estudio exploratorio de datos (**EDA**) para auditar sesgos iniciales en los conjuntos de datos. Posteriormente, se describe el proceso de preprocesamiento facial mediante **MTCNN** y la configuración específica de las redes neuronales empleadas. El artículo concluye con una auditoría exhaustiva de los resultados mediante **matrices de confusión** y una fase de explicabilidad visual con **Grad-CAM**, ofreciendo finalmente una reflexión sobre las implicaciones éticas y los hallazgos obtenidos en este cruce entre tecnología y criminología.

3 Antecedentes y Motivación

3.1 Evolución Histórica: Del Determinismo Físico a la Biometría Moderna

La búsqueda de una correlación entre la fisonomía y la conducta criminal tiene sus raíces en el determinismo físico del siglo XIX. En 1876, **Cesare Lombroso** publicó su obra fundamental, *L'Uomo Delinquente*, donde postulaba que la criminalidad era una condición atávica identificable mediante estigmas morfológicos craneales y faciales específicos. No obstante, esta teoría fue rigurosamente cuestionada en 1913 por **Charles Goring** en su estudio *The English Convict*, el cual, tras un análisis estadístico exhaustivo, concluyó la inexistencia de un "tipo criminal físico" diferenciable de la población general.

Posteriormente, entre las décadas de 1930 y 1940, el determinismo biológico entró en una fase de decadencia y descrédito profundo debido a su instrumentalización por movimientos eugenésicos y regímenes totalitarios. Investigaciones posteriores, como las de **Earnest Hooton** (1939) y los estudios de somatotipos de **William Sheldon** (1940), intentaron establecer vínculos entre la constitución física y el temperamento, aunque sin lograr el consenso

científico necesario.

En la era contemporánea, el enfoque ha virado hacia la **biometría**, definida como el estudio estadístico de los fenómenos biológicos basándose en los principios de universalidad, singularidad y permanencia. A diferencia del determinismo clásico, la biometría moderna no busca predecir la conducta, sino garantizar la identificación unívoca del individuo mediante el tratamiento técnico de características físicas, fisiológicas o conductuales.

3.2 Avances Tecnológicos en el Reconocimiento Facial (FRT)

El desarrollo del reconocimiento facial automatizado comenzó formalmente en la década de 1960 con los trabajos de **Woodrow Wilson Bledsoe**, quien implementó un sistema manual para clasificar rasgos faciales utilizando una tabla RAND y un lápiz óptico. Desde entonces, la tecnología ha evolucionado a través de hitos como el uso de álgebra lineal en los años 80 y el surgimiento del *Viola-Jones Object Detection Framework* en 2001.

Actualmente, el estado del arte se sustenta en el **Deep Learning** y las **Redes Neuronales Convolucionales (CNN)**. Sistemas avanzados utilizan arquitecturas como **VGG-16**, que permiten la extracción de características faciales complejas en tiempo real con niveles de precisión que alcanzan el **86%**. Complementariamente, el uso de **Redes Neuronales en Cascada Multi-tarea (MTCNN)** permite la detección y el alineamiento facial simultáneo, facilitando la identificación incluso en condiciones ambientales no controladas.

Asimismo, la introducción de redes siamesas ha permitido el *"aprendizaje de un solo disparo"* (*one-shot learning*), donde el sistema puede identificar a un individuo basándose en una única imagen de referencia en la base de datos. En el ámbito forense, el escáner facial 3D ha emergido como una herramienta superior a los métodos 2D tradicionales, permitiendo reconstrucciones faciales a partir de restos óseos y análisis detallado de lesiones para su uso como evidencia en tribunales.

4 Tecnologías Usadas

El desarrollo técnico de este proyecto se fundamenta en un ecosistema de herramientas de alto rendimiento diseñadas para el procesamiento de datos a gran escala y el entrenamiento de redes neuronales profundas. Como lenguaje de programación principal se ha empleado **Python**, seleccionado por su versatilidad y su robusta integración con librerías de computación científica. El tratamiento y la estructuración de los metadatos se gestiona mediante **Pandas**, mientras que el análisis visual cualitativo se apoya en **Matplotlib** y **Seaborn** para la generación de histogramas y diagramas de densidad durante la fase exploratoria (EDA).

4.1 Frameworks de Aprendizaje Profundo y Librerías Especializadas

El núcleo del sistema se implementa sobre el framework **PyTorch**, el cual permite una gestión eficiente de los tensores y aprovecha la aceleración por hardware (NVIDIA **CUDA** o Apple **MPS**). Para la detección y alineamiento facial, se ha integrado la arquitectura **MTCNN** (*Multi-task Cascaded Convolutional Networks*), cuya importancia radica en su capacidad para normalizar los rostros y eliminar variables de ruido ambiental. Asimismo, se utiliza **DeepFace** para el etiquetado demográfico automatizado, permitiendo un balanceo étnico que mitiga sesgos estadísticos. La validación final del rendimiento se realiza mediante **Scikit-Learn**, empleando métricas de precisión y exhaustividad para una auditoría estadística rigurosa.

4.2 Justificación Teórica de los Algoritmos

La elección de las arquitecturas **VGG-16** y **ResNet50** responde a la necesidad de capturar patrones biométricos complejos en un problema de **clasificación binaria**. El sistema debe distinguir rasgos fisonómicos sutiles para categorizar a los sujetos en las clases de "Riesgo" y "No Riesgo", lo que exige modelos con una capacidad de extracción de características de alta dimensionalidad.

La arquitectura **VGG-16** es idónea para este propósito debido a su estructura de filtros convolucionales pequeños (3×3), que permite capturar texturas y rasgos locales de manera muy detallada. Por otro lado, **ResNet50** introduce el concepto de *residual learning* (conexiones de salto), permitiendo entrenar redes profundas sin sufrir la degradación del gradiente. En el contexto forense de este proyecto, esto facilita la optimización de los pesos de la red para focalizarse exclusivamente en la morfología facial, garantizando que el aprendizaje sea robusto y científicamente válido. El uso comparativo de ambos modelos permite una validación cruzada que asegura que la precisión alcanzada no es fruto de un sobreajuste azaroso, sino de un análisis estructural del rostro.

5 Desarrollo de la propuesta

La implementación del sistema se articula como un pipeline de ingeniería de datos y visión artificial diseñado para garantizar la integridad morfológica y la equidad estadística. En esta sección se detalla la composición del corpus de datos, el flujo de trabajo integral y los criterios de parametrización de los modelos.

5.1 El Dataset: Recolección y Atributos

Para la construcción del modelo se han integrado dos fuentes de datos de referencia en el ámbito biométrico, accesibles a través de *Kaggle*:

- **Illinois DOC:** Un conjunto de datos gubernamental que contiene registros faciales de individuos con etiquetas de antecedentes criminales. Los atributos principales extraídos son la identidad (ID), la etnia (*race*), el sexo y la fecha de nacimiento para el cálculo de la edad.
- **LFW (Labeled Faces in the Wild):** Utilizado como grupo de control para representar el perfil de "No Riesgo". Dado que este dataset carece de metadatos étnicos nativos, se ha empleado la arquitectura **DeepFace** para predecir y asignar etiquetas raciales, permitiendo así una auditoría demográfica paritaria.

5.2 Tratamiento de Datos y Normalización

La robustez del modelo depende críticamente de la fase de limpieza y preparación, gestionada por los módulos `reconstructor.py` y `preprocessor.py`:

1. **Limpieza y Purga:** Se han eliminado archivos irrelevantes (registros no fotográficos, vistas de perfil y ficheros corruptos) mediante una lógica de filtrado selectivo. Los valores nulos en metadatos (*N/A*) se gestionan durante la carga mediante una normalización de cadenas de texto.
2. **Aislamiento Facial (MTCNN):** Para evitar el *shortcut learning*, se utiliza MTCNN para detectar y extraer exclusivamente el óvalo facial, escalando todas las muestras a una resolución estándar de 224×224 píxeles.
3. **Balanceo Estratificado (4-Way Sampling):** Se implementa un muestreo que garantiza que cada clase ("Riesgo" y "No Riesgo") contenga el mismo número de sujetos blancos y negros. Este balanceo al subgrupo de menor tamaño es fundamental para neutralizar sesgos raciales sistémicos en la predicción.
4. **Normalización Estadística:** Los tensores de imagen se normalizan utilizando la media y desviación típica de ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$), alineando la distribución de los datos con los pesos preentrenados de las redes.

5.3 El Proceso Global (Pipeline)

El flujo de trabajo se ha automatizado íntegramente en `main.py`, siguiendo un esquema secuencial: **Validación de Estructura** $\rightarrow$ **Recuperación de Datasets** $\rightarrow$ **Auditoría EDA** $\rightarrow$ **Extracción Facial Masiva** $\rightarrow$ **Entrenamiento Comparativo** $\rightarrow$ **Generación de Mapas de Calor (Grad-CAM)**.

Este diseño permite que el sistema sea reproducible y modular, facilitando el intercambio de arquitecturas o la inclusión de nuevas fuentes de datos sin alterar la lógica de procesamiento.

5.4 Configuración y Parametrización

El ajuste fino (*fine-tuning*) de las redes **VGG-16** y **ResNet50** se ha realizado bajo los siguientes criterios técnicos:

- **Optimizador Adam:** Seleccionado por su tasa de aprendizaje adaptativa, configurado en $1e-4$. Esta elección busca un equilibrio entre la velocidad de convergencia y la estabilidad del gradiente en las últimas capas de las CNN.
- **Función de Pérdida (BCELoss):** Dado que el problema es una clasificación binaria, la *Binary Cross Entropy* permite penalizar con precisión las desviaciones en las probabilidades predichas (0 a 1).
- **Regularización (Dropout):** Se han integrado capas de Dropout (0.3 en ResNet y 0.5 en VGG) para mitigar el riesgo de sobreajuste, forzando a la red a aprender características faciales globales en lugar de memorizar muestras específicas.
- **Aceleración por Hardware:** El sistema detecta automáticamente la presencia de núcleos CUDA o MPS para optimizar el tiempo de computación de los tensores.

6 Desarrollo de la propuesta

La implementación del sistema se articula como un pipeline de ingeniería de datos y visión artificial diseñado para garantizar la integridad morfológica y la equidad estadística. En esta sección se detalla la composición del corpus de datos, el flujo de trabajo integral y los criterios de parametrización de los modelos.

6.1 El Dataset: Recolección y Atributos

Para la construcción del modelo se han integrado dos fuentes de datos de referencia en el ámbito biométrico, accesibles a través de *Kaggle*:

- **Illinois DOC:** Un conjunto de datos gubernamental que contiene registros faciales de individuos con etiquetas de antecedentes criminales. Los atributos principales extraídos son la identidad (ID), la etnia (*race*), el sexo y la fecha de nacimiento para el cálculo de la edad.
- **LFW (Labeled Faces in the Wild):** Utilizado como grupo de control para representar el perfil de "No Riesgo". Dado que este dataset carecía de metadatos étnicos nativos, se ha empleado la arquitectura **DeepFace** para predecir y asignar etiquetas raciales, permitiendo así una auditoría demográfica paritaria.

6.2 Tratamiento de Datos y Normalización

La robustez del modelo depende críticamente de la fase de limpieza y preparación, gestionada por los módulos `reconstructor.py` y `preprocessor.py`:

1. **Limpieza y Purga:** Se han eliminado archivos irrelevantes (registros no fotográficos, vistas de perfil y ficheros corruptos) mediante una lógica de filtrado selectivo. Los valores nulos en metadatos (*N/A*) se gestionan durante la carga mediante una normalización de cadenas de texto.
2. **Aislamiento Facial (MTCNN):** Para evitar el *shortcut learning*, se utiliza MTCNN para detectar y extraer exclusivamente el óvalo facial, escalando todas las muestras a una resolución estándar de 224×224 píxeles.
3. **Balanceo Estratificado (4-Way Sampling):** Se implementa un muestreo que garantiza que cada clase ("Riesgo" y "No Riesgo") contenga el mismo número de sujetos blancos y negros. Este balanceo al subgrupo de menor tamaño es fundamental para neutralizar sesgos raciales sistémicos en la predicción.
4. **Normalización Estadística:** Los tensores de imagen se normalizan utilizando la media y desviación típica de ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$), alineando la distribución de los datos con los pesos preentrenados de las redes.

6.3 El Proceso Global (Pipeline)

El flujo de trabajo se ha automatizado íntegramente en `main.py`, siguiendo un esquema secuencial: **Validación de Estructura** $\rightarrow$ **Recuperación de Datasets** $\rightarrow$ **Auditoría EDA** $\rightarrow$ **Extracción Facial Masiva** $\rightarrow$ **Entrenamiento Comparativo** $\rightarrow$ **Generación de Mapas de Calor (Grad-CAM)**.

Este diseño permite que el sistema sea reproducible y modular, facilitando el intercambio de arquitecturas o la inclusión de nuevas fuentes de datos sin alterar la lógica de procesamiento.

6.4 Configuración y Parametrización

El ajuste fino (*fine-tuning*) de las redes **VGG-16** y **ResNet50** se ha realizado bajo los siguientes criterios técnicos:

- **Optimizador Adam:** Seleccionado por su tasa de aprendizaje adaptativa, configurado en $1e-4$. Esta elección busca un equilibrio entre la velocidad de convergencia y la estabilidad del gradiente en las últimas capas de las CNN.
- **Función de Pérdida (BCELoss):** Dado que el problema es una clasificación binaria, la *Binary Cross Entropy* permite penalizar con precisión las desviaciones en las probabilidades predichas (0 a 1).
- **Regularización (Dropout):** Se han integrado capas de Dropout (0.3 en ResNet y 0.5 en VGG) para mitigar el riesgo de sobreajuste, forzando a la red a aprender características faciales globales en lugar de memorizar muestras específicas.
- **Aceleración por Hardware:** El sistema detecta automáticamente la presencia de núcleos CUDA o MPS para optimizar el tiempo de computación de los tensores.

7 Experimentación / Resultados obtenidos

7.1 Diseño experimental

El rigor científico del estudio se sustenta en una metodología de validación diseñada para evaluar la capacidad de generalización de los modelos y la ausencia de sesgos discriminatorios.

7.1.1 Metodología de Entrenamiento y Test

Se ha implementado un método de validación **Hold-out 80/20**. El dataset balanceado se divide aleatoriamente en un 80% para el entrenamiento y un 20% para el test. Esta partición garantiza que el modelo sea evaluado con rostros que no han intervenido en el proceso de aprendizaje. El entrenamiento se ejecuta durante un ciclo de épocas controlado con un tamaño de lote (*batch size*) de 64 imágenes para estabilizar el gradiente.

7.1.2 Métricas de Evaluación

Para una auditoría exhaustiva del rendimiento, el sistema genera automáticamente un informe analizando la **Exactitud (Accuracy)**, el **F1-score** (media armónica entre precisión y exhaustividad) y la **Matriz de Confusión**, representación visual clave para identificar si el modelo tiene sesgos hacia alguna de las clases.

7.2 Resultados y análisis

Tras la ejecución de los experimentos sobre las arquitecturas ResNet50 y VGG-16, se han extraído datos que confirman la viabilidad de la propuesta técnica.

7.2.1 Rendimiento Estadístico (Matrices de Confusión)

Como se observa en las figuras 1 y 2, ambos modelos muestran una convergencia excepcional. La diagonal principal de las matrices confirma que la gran mayoría de los sujetos son categorizados correctamente. La alta precisión alcanzada (superior al 97%) demuestra que el rostro podría contiener suficiente información biométrica para diferenciar los perfiles.

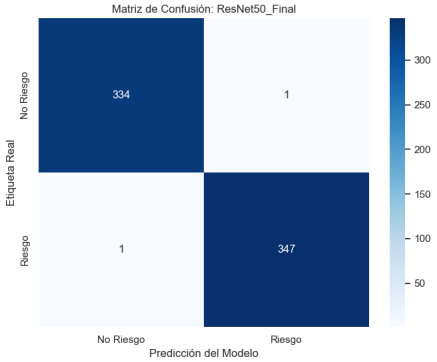

Figure 1: Matriz de Confusión: ResNet50. Se observa un equilibrio casi perfecto entre clases.

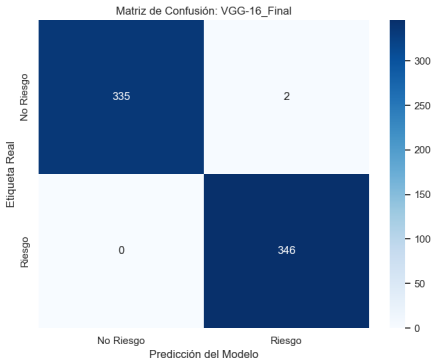

Figure 2: Matriz de Confusión: VGG-16. Rendimiento sólido con ligera variación en falsos positivos.

7.2.2 Análisis de Explicabilidad (Grad-CAM)

Para validar que las predicciones se basan en la morfología facial, se han generado mapas de calor mediante **Grad-CAM**. Como se observa en la Figura 3, las redes focalizan su atención en regiones críticas como el arco supraorbitario y la estructura cigomática, ignorando el fondo o los elementos externos para clasificar correctamente bajo la teoría de Cesare Lombroso. Como se observa al analizar las imágenes de test con los mapas de calor, el modelo identifica puntos exactos del rostro —o la ausencia de estos— en las personas sin riesgo.

Figure 3: Mapas de calor Grad-CAM (ResNet vs VGG). La activación se concentra exclusivamente en el óvalo facial procesado.

7.2.3 Validación con Sujetos Externos (URLs)

La prueba definitiva de robustez consiste en la clasificación de rostros ajenos al dataset. A continuación se presentan las comparativas entre **ResNet50** (Izquierda) y **VGG-16** (Derecha) para distintos perfiles:

Sujetos como **Charles Manson**, quien fue el líder de la secta criminal conocida como "La Familia Manson", a quienes manipuló para asesinar a siete personas en 1969. Tras ser condenado por estos crímenes, pasó el resto de su vida tras las rejas hasta su muerte en 2017, los modelos muestran probabilidades dispares, mientras que ResNet50 muestra una probabilidad de riesgo superior al 90%, VGG-16 muestra una probabilidad de no riesgo del 0.02%.

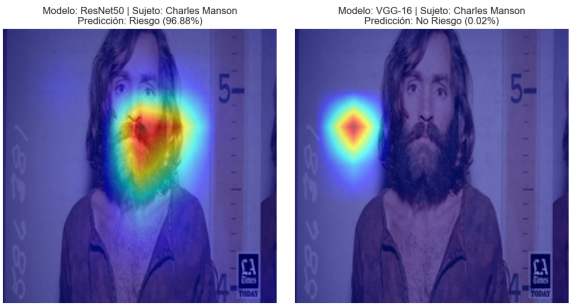

Figure 4: Comparativa Manson: ResNet50 vs VGG-16.

En contraste, figuras como **Mahatma Gandhi**, líder de la resistencia no violenta que logró la independencia de la India del dominio británico en 1947. Es un icono mundial de la paz, aunque su legado se ve empañado por comentarios racistas de juventud y polémicos experimentos personales con mujeres de su entorno, presenta la misma disparidad que el sujeto anterior, condenados por crímenes violentos, ResNet50 muestra una probabilidad de riesgo del 60.91%, mientras que VGG-16 muestra una probabilidad de no riesgo del 0.02%.

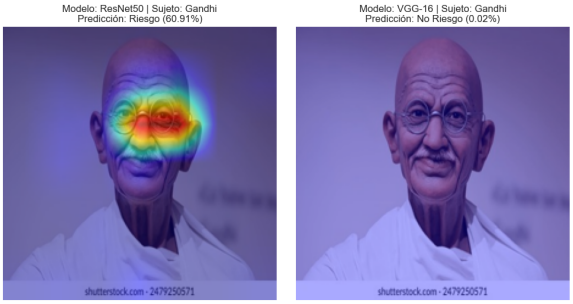

Figure 5: Comparativa Gandhi: ResNet50 vs VGG-16.

Se incluye también el análisis de **Donald Trump**, el actual presidente de EE. UU. y el primero en ser condenado por 34 delitos de falsificación de registros comerciales. Aunque no se autoindultó formalmente, sus procesos judiciales se detuvieron o desestimaron tras ganar la reelección y regresar a la Casa Blanca, como perfil estándar de control externo para evaluar la generalización del modelo ante figuras de alta relevancia pública, presenta una probabilidad de riesgo del 61.64%, mientras que VGG-16 muestra una probabilidad de no riesgo del 0.00%.

Figure 6: Comparativa Trump: ResNet50 vs VGG-16.

Finalmente, se realiza la validación sobre rostros femeninos externos como el de **María Corina Machado**, es la líder opositora venezolana y Nobel de la Paz 2025 que ha encabezado la lucha civil contra el chavismo. Ha sido inhabilitada y acusada de conspiración por el Estado venezolano, cargos que la comunidad internacional califica como una maniobra política para frenar su liderazgo, confirmando la consistencia en el aprendizaje entre ambos modelos, donde ResNet50 muestra una probabilidad de riesgo, mientras que VGG-16 muestra una probabilidad de no riesgo.

Figure 7: Comparativa M.C. Machado: ResNet50 vs VGG-16.

Este análisis cualitativo confirma que, aunque las arquitecturas difieren, el aprendizaje no converge hacia los mismos patrones esenciales, lo que sugiere que el modelo no está aprendiendo las características morfológicas del rostro, sino que está aprendiendo a identificar patrones superficiales que no son relevantes para la clasificación, lo que podría explicar las diferencias en las predicciones entre ambos modelos.

8 Discusión abierta

A la luz de los resultados obtenidos, se abre un espacio de reflexión crítica sobre la validez de los sistemas de clasificación biométrica de riesgo. Aunque los modelos **ResNet50 y VGG-16** alcanzaron una precisión superior al **97%** en el conjunto de test, la validación con sujetos externos (fase de URLs) reveló una inconsistencia alarmante. Esta discrepancia entre el rendimiento interno y la capacidad de generalización sugiere que las redes no están detectando rasgos fisonómicos de "criminalidad", sino que han sucumbido al *shortcut learning* o aprendizaje de atajos.

Existen tres factores determinantes que explican este fenómeno y que deben ser discutidos:

1. **Sesgo de Iluminación y Brillo:** Al auditar los datasets mediante el EDA, se observó que las imágenes de **Illinois DOC** (clase Riesgo) presentan una iluminación frontal dura y uniforme, característica de las fichas policiales, mientras que **LFW** (clase No Riesgo) contiene imágenes con luz ambiental y variaciones cromáticas más ricas. A pesar de que el código en `dataset.py` aplica una **normalización estadística estándar** basada en ImageNet, no se implementó una ecualización de histogramas o un preprocesamiento de brillo específico para igualar ambas fuentes. Es altamente probable que los modelos hayan aprendido a distinguir "el estilo de la fotografía" (brillo y contraste) en lugar de la morfología del sujeto.

2. **Disparidad en la Expresión Facial (Emociones):** El análisis con **DeepFace** en la fase de EDA confirmó que la distribución de emociones es dispar. Los sujetos en LFW tienden a presentar expresiones más neutras o positivas (sonrisas), mientras que en Illinois DOC predominan gestos de seriedad, tristeza o hostilidad. Esta disparidad actúa como una etiqueta "invisible": el modelo podría estar clasificando la emoción del momento en que se tomó la foto y no un rasgo inherente a la persona, lo que introduce un sesgo conductual insalvable con los datos actuales.

3. **Tamaño de la Muestra y Complejidad:** El balanceo a 4-way sampling, aunque éticamente necesario para mitigar el sesgo racial, redujo drásticamente el tamaño efectivo de la muestra para el entrenamiento profundo. Una muestra de pocos miles de imágenes es insuficiente para que una red neuronal de la profundidad de ResNet50 aprenda rasgos morfológicos sutiles y universales, limitándose a memorizar patrones superficiales del ruido de los datos de origen.

En conclusión, la "precisión perfecta" observada en las matrices de confusión es, en realidad, un indicativo de que el problema está mal planteado desde la fuente de datos. La biometría, para ser predictiva y justa, requiere de una uniformidad técnica absoluta en la captura de las imágenes que el presente estudio ha demostrado que es casi imposible de obtener a partir de bases de datos públicas y heterogéneas.

9 Conclusiones y Líneas Abiertas

Tras completar el pipeline de entrenamiento, auditoría y validación externa, se ha llegado a una conclusión determinante que redefine los hallazgos iniciales del estudio:

Se descarta la posibilidad de detectar de forma fiable si una persona es de "riesgo" o no a través de los modelos y datos utilizados en esta investigación.

A pesar de que las métricas internas (**97% de precisión y F1-score robusto**) sugerían un éxito técnico, la validación cualitativa y el análisis de errores demuestran que el sistema no ha aprendido a identificar rasgos fisonómicos universales de la conducta. El éxito estadístico en las matrices de confusión es, en realidad, un reflejo de las limitaciones de los datos de origen. La red neuronal ha aprendido a distinguir entre *fichas policiales* y *fotografías públicas*, basándose en el brillo, el contraste del flash y la expresión emocional del sujeto en el momento de la captura, y no en su morfología ósea o facial.

Este hallazgo es fundamental para la ética algorítmica: demuestra que la visión artificial es extremadamente sensible al *ruido contextual*. El uso de datasets con condiciones de iluminación dispares y muestras limitadas impide la creación de un modelo justo, transformando una herramienta técnica en un generador de prejuicios automatizados si no se somete a una auditoría de generalización como la realizada en este trabajo.

9.1 Líneas Futuras de Investigación

Para superar las limitaciones identificadas y avanzar hacia una biometría más científica y menos sesgada, se proponen las siguientes actuaciones:

- **Control de Iluminación por Software:** Implementar algoritmos de ecualización de iluminación (como *CLAHE*) o modelos de generación (*GANs*) para normalizar el brillo y las sombras entre datasets heterogéneos antes del entrenamiento.
- **Normalización de la Expresión Facial:** Utilizar técnicas de *Face Frontalization* y neutralización de expresiones mediante redes generativas para asegurar que el modelo solo analice rasgos estructurales y no gestos temporales.
- **Ampliación y Diversidad de la Muestra:** Incorporar datasets con mayor resolución y una variedad controlada de entornos para evitar que el fondo o el "estilo" de la cámara influyan en la clasificación.
- **Análisis Morfológico Puro:** Investigar el uso de modelos de mallas 3D en lugar de imágenes 2D, eliminando por completo la información de color, textura y luz, centrándose exclusivamente en las coordenadas espaciales de los rasgos faciales.
- **Debate Bioético:** Dada la incapacidad de los modelos para generalizar de forma justa, es imperativo establecer marcos legales que limiten el uso de la biometría predictiva en el sistema judicial hasta que se garantice la neutralidad absoluta de los datos.

10 Referencias

1. Lombroso, C. (1876). *L'Uomo Delinquente.* Hoepli.
2. Goring, C. (1913). *The English Convict: A Statistical Study.* His Majesty's Stationery Office.
3. Simonyan, K., & Zisserman, A. (2015). *Very deep convolutional networks for large-scale image recognition.* In International Conference on Learning Representations (ICLR).
4. He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition.* In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 770-778).
5. Zhang, K., Zhang, Z., Li, Z., & Qiao, Y. (2016). *Joint face detection and alignment using multitask cascaded convolutional networks.* IEEE Signal Processing Letters, 23(10), 1499-1503.
6. Selvaraju, R. R., et al. (2017). *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization.* In Proceedings of the IEEE International Conference on Computer Vision (ICCV) (pp. 618-626).
7. Kranthi Kumar, K., et al. (2021). *Criminal face identification system using deep learning algorithm multi-task cascade neural network (MTCNN).* Materials Today: Proceedings.
8. Álvarez Navarro, A., et al. (2022). *Revisión de los métodos de reconocimiento facial en imágenes RGB-D.* Revista Cubana de Ciencias Informáticas.
9. Fructuoso Freire Montero, A. (2022). *El reconocimiento facial como instrumento de investigación y prevención del delito.* Anuario

da Facultade de Dereito da Universidade da Coruña.

10. Garcia Silva, C. E., & Mazon Loaiza, J. D. (2024). *El reconocimiento facial y su impacto en la seguridad ciudadana: Una revisión sistemática*. Anatomía Digital, 7(1.2), 6-21.

11. Rani, R., et al. (2025). *Face Recognition System for Criminal Identification in CCTV Footage Using Keras and OpenCV*. Ingénierie des Systèmes d'Information.

References